

基于 CNN 与 U-Net 的晶圆缺陷自动检测系统

李彦昊 2012286 软件工程 特色班

一、研究背景

半导体制造已然成为现代工业最为重要的行业之一，晶圆制造工艺通常涉及数百个集成电路模块，由于制造过程的复杂性和动态性，半导体晶圆容易出现缺陷。晶圆图上的典型缺陷图案通常是由特定的设备故障或工艺变化引起的。例如，边缘环形缺陷一般由错误蚀刻所引起，线性类缺陷是由于机器与晶圆片的摩擦，中心类缺陷，通常因薄膜沉积产生。由此可见，缺陷图案和制程中的异常高度相关。通过分析晶圆图这一类直观的数据，能够辅助工程师高效地回溯故障成因，定位问题并加以解决，有效减少半导体制造过程中的返工率和废品率，有助于企业提高生产效率并降低成本。

二、研究现状

（一）单缺陷图案晶圆图

目前已有的单缺陷晶圆图分类方法为有监督和无监督两大类。有监督学习方法性能良好，比如 SVM、反向传播算法、高斯混合模型等，但需要大量标签样本支撑训练。然而，有标签晶圆图数量通常有限，且大量晶圆图需要进行人工标识，这会导致所提取的特征具有一定的主观性和局限性，特别是在工艺开发或产品早期生产阶段。无监督学习不需要标签的指导，但由于缺乏有标签样本的训练，性能往往不如有监督学习。

（二）混合缺陷图案晶圆图

集成电路生产过程的高度复杂性导致故障频发，单个晶圆可能会受到多于一个故障的影响，单张晶圆图上可能存在多个缺陷图案。分析处理混合缺陷图案晶圆图有着如下问题：存在晶圆图上的同一区域受到不同类型的异常影响，导致缺

陷图案重叠，影响准确地进行类别判断。


目前热门的深度学习分类单缺陷图案晶圆图时具有优异的性能，但直接处理多缺陷图案晶圆图时不能获得很好的效果。因此，为了更准确地分析晶圆图，需要将多缺陷图案晶圆图上的多个缺陷图案分离后再独立进行分析。单张晶圆图上多个缺陷图案可以看成不同的类。对晶圆图上的缺陷芯片进行聚类从而分离多个缺陷图案，即可使用单分类器进行分类。

三、数据格式


数据来源于阿里天池实验室的混合模式晶圆图缺陷数据集 `Wafer_Map_Datasets.npz.zip`。该数据是由某晶圆制造厂采集的晶圆图数据，这些晶圆图是通过对晶圆片上的每一个晶粒进行电学性能测试得到。但实际采集到各类型的晶圆图在数量分布上存在较大差异，为了保持各类型数据间的平衡，采用对抗生成网络生成了部分晶圆图。最终形成了约 38000 张的混合模式晶圆图缺陷数据集，用于识别混合模式晶圆图缺陷，并辅助晶圆制造工艺中缺陷成因的研究。

`["arr_0"]`：混合模式晶圆图缺陷数据，0 表示空白点，1 代表通过电学测试的正常晶粒，2 代表未通过电学测试的失效晶粒。数据形状为 52×52 。

`["arr_1"]`：混合模式晶圆图缺陷标签，采用 one-hot 编码，共 8 维，分别对应晶圆图缺陷的 8 种基本类型（单一缺陷）。



(arr_0 单缺陷图案晶圆图示例)



(arr_0 混合缺陷图案晶圆图示例)

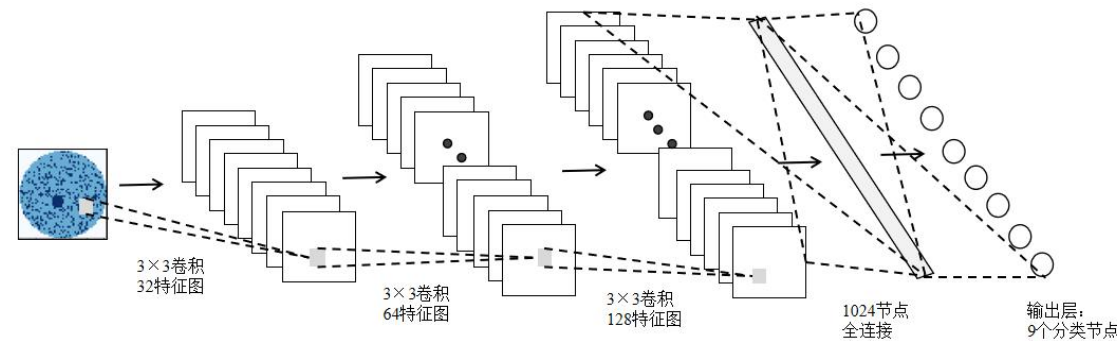
四、候选算法

(一) 单缺陷图案晶圆图

由卷积神经网络(CNN)确定单缺陷图案的类型，模型结构如图所示。利用 ReLU 激活函数的卷积单元进行特征提取，卷积单元的步长设置为 2。全连接层整合并展平前层输出的特征，用于后续分类。Softmax 输出层由前层网络的输出特征得到一个概率向量作为输出结果。其中，概率向量中的每个维度对应一个缺陷图案类别，每个维度值代表输入晶圆图属于这个类别的可能性大小。损失函数定义为：

$$J = -\frac{1}{n_{\text{wafer}}} \sum_{i=1}^{n_{\text{wafer}}} \sum_{j=1}^{n_{\text{class}}} \text{lable}_{\text{true_ij}} \log \text{lable}_{\text{pre_ij}}$$

其中， n_{wafer} 是输入晶圆图数量， n_{class} 是缺陷图案的类别数。 $\text{lable}_{\text{pre_ij}}$ 和 $\text{lable}_{\text{true_ij}}$ 是晶圆图 W_i 属于第 j 类的预测概率和真实概率。最终 Softmax 输出层结果就是单缺陷图案圆晶图的预测结果。



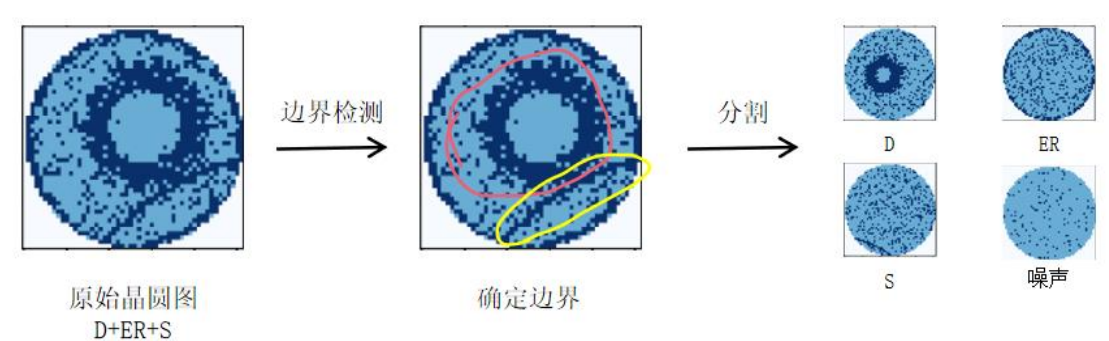
(CNN 模型结构示意图)

(二) 混合缺陷图案晶圆图

混合缺陷图案晶圆图在平常检测过程中占比较高，因此需要准确地分析混合缺陷晶圆图。由于混合缺陷晶圆图噪声较多、同时特征多但特征相似性较高，传统的多分类方法对于直接分类混合缺陷图案晶圆图难获得理想的效果。因此在此考虑将混合缺陷图案晶圆图上的多个缺陷图案分离后再独立进行分析。单张晶


圆图上多个缺陷图案可以看成不同的类。再对不同类的晶圆图进行单缺陷图案晶圆图分析。

因此混合缺陷晶圆图的主要算法就是找到能够分割复杂混合缺陷图案的分割算法。深度学习中的 U 型网络(U-Net)基于设定的分割标签，对输入图像进行像素级（pixel to pixel）预测，符合我们问题的特性，适用于混合缺陷晶圆图的分割分类问题。边界检测模型采用 U 型网络结构，确定晶圆图上多个缺陷图案团的边界，进而将多缺陷图案晶圆图分解为多张包含一个缺陷图案团的晶圆图和随机分布的噪声，基本实现逻辑如图所示。

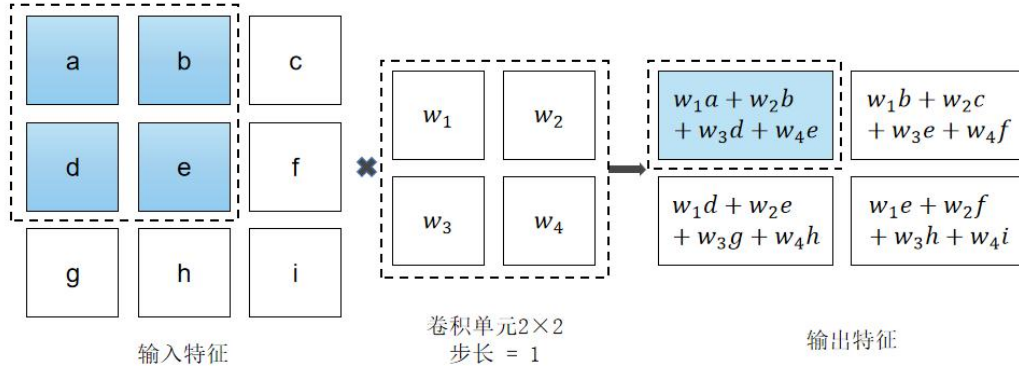


(混合缺陷图案晶圆图检测分割逻辑)

使用 U-net 模型的输入为二值晶圆图,边界检测的 U 型网络结构如下图所示,缺陷图案区域和无缺陷区域的像素值为 1 和 0。输出图像与输入图像具有相同分辨率,保留缺陷图案区域,同时新增缺陷图案团的边界。边界、缺陷图案区域和无缺陷区域的像素值分别为 2、1 和 0。边界检测法将晶圆图上的单个缺陷图案、重叠缺陷图案团及离散全局噪声进行分离。



(边界检测的 U 型网络结构)



在特征提取过程中，U-Net 使用卷积单元捕捉晶圆特征，卷积操作定义为：

$$O_{ij} = \sigma \left(\sum_{x=1}^{u_1} \sum_{y=1}^{u_2} U(x, y) Z(x + (i - 1) * s, y + (j - 1) * s) + bias \right)$$

其中， O_{ij} 是输出图上节点(i,j)的输出值。输入映射 Z 和卷积单元 U 的大小为 $z_1 \times z_2$ 和 $u_1 \times u_2$ 。 $\sigma()$ 为非线性激活函数，本章中使用修正线性单元(ReLU)。 $bias$ 是偏置项， s 是卷积单元移动的步长。

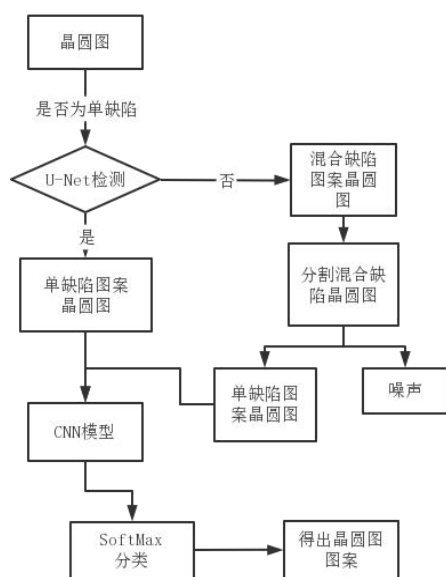
由于晶圆图上无缺陷区域(负样本)占据大部分区域，而目标区域缺陷图案团边界(正样本)占的比例较小，会引起分类数据不平衡的问题，影响到 U-Net 网络的正常训练。因此采用加权分类交叉熵优化函数来解决这一问题，根据验证集的性能，将边界区域、缺陷图案区域、无缺陷图案区域的权重比例分别设置为 1: 0.5: 0.2，U-Net 损失函数定义为：

$$J = -\frac{1}{n_{wafer}} \sum_{i=1}^{n_{wafer}} \frac{\sum_{j=1}^{n_{die}} weight_{ij} \sum_{k=1}^{k_{num}} lable_{true_ijk} \log lable_{pre_ijk}}{\sum_{j=1}^{n_{die}} weight_{ij}}$$

其中， n_{die} 是一张晶圆图上像素总值， n_{wafer} 是输入晶圆图数量。 $lable_{true_ijk}$ 、 $lable_{pre_ijk}$ 和 $weight_{ij}$ 是晶圆图 i 上像素点 j 的真实标签概率向量、预测标签概率向量和权重值， k_{num} 是像素点的类别数。

五、实验计划

在具体实践过程中，由于获得的数据来自天池实验室的公开数据，晶圆图比实际生产中晶圆图的噪声少，因此在此实验前不进行降噪处理。具体实验过程如下述流程图所示



(实验计划流程图)

六、评价指标

对于整个系统的识别性能，采用常见的平均准确率 A (Averages)、精确率 P (precision)、召回率 R (Recall) 两种量化指标进行评价。

各指标公式如下所示：

$$A = \frac{TP}{n_{\text{wafer}}} \times 100\%$$

$$P = \frac{TP}{TP+FP} \times 100\%$$

$$R = \frac{TP}{TP+FN} \times 100\%$$

其中：

n_{wafer} 是所有晶圆图样例个数。

True Positives(TP): 表示将实际为正样例预测为正样例。

False Positives(FP): 表示将实际为负样例预测为正样例。

False Negative(FN): 表示将实际为正样例预测为负样例。

七、参考文献

- [1] 张雨璇. 基于迁移学习的晶圆图缺陷模式识别与分类方法研究 [D]. 桂林电子科技大学, 2021.DOI:10.27049/d.cnki.ggldc.2021.000174.
- [2] 孔煜婷. 基于深度学习的晶圆图分析[D].浙江大学, 2021.DOI:10.27461/d.cnki.gzjdx.2021.001205.
- [3] 余建波,卢笑蕾,宗卫周.基于局部与非局部线性判别分析和高斯混合模型动态集成的晶圆表面缺陷探测与识别 [J]. 自动化学报,2016,42(01):47-59.DOI:10.16383/j.aas.2016.c150311.
- [4] 沈宗礼,余建波.基于迁移学习与深度森林的晶圆图缺陷识别 [J]. 浙江大学学报(工学版),2020,54(06):1228-1239.
- [5] J. Wang, C. Xu, Z. Yang, J. Zhang and X. Li, "Deformable Convolutional Networks for Efficient Mixed-Type Wafer Defect Pattern Recognition," in IEEE Transactions on Semiconductor Manufacturing, vol. 33, no. 4, pp. 587-596, Nov. 2020, doi: 10.1109/TSM.2020.3020985.
- [6] <https://zhuanlan.zhihu.com/p/47184529>
- [7] <https://easyai.tech/ai-definition/cnn/>
- [8] <https://tianchi.aliyun.com/dataset/dataDetail?dataId=77328#1>